



Apache Airflow를 활용한

데이터 파이프라인 자동화



코드잇 스프린트

데이터 분석가 과정 대표 강사

| 프로필

Name 이현수
E-mail hyunsoo.it@gmail.com
전공 연세대학교 기계공학

| 경력

- 데이터 분석/엔지니어링 전문 강사
- 코드잇 콘텐츠 파트너 (데이터 엔지니어링 오버뷰)
- AWS 클라우드 기초 시험 자격증 강의 제작 (메타코드)
- (전) 천재교육 데이터 엔지니어
- (전) KDT 빅데이터 과정 강사 (데이터 분석, 데이터 엔지니어링, 클라우드)

| 자격증

정보처리기사	AWS Data Analytics - Specialty
빅데이터분석기사	AWS Solutions Architect - Associate
Apache Spark Associate Developer	AWS Developer - Associate

| 개인 사이트




- 01 데이터 엔지니어링 개요
- 02 Apache Airflow 소개
- 03 Airflow 관련 용어 정리
- 04 Airflow 아키텍처 및 구성 요소
- 05 Airflow DAG 스크립트 구조
- 06 데이터 파이프라인 자동화 사례

01 데이터 엔지니어링 개요


엔지니어링의 정의

- 공업 분야의 응용과학 기술을 연구하는 학문 또는 과학적, 경제학적, 사회적 원리와 실용적 지식을 활용하여 새로운 제품, 도구, 건축물 · 조형물, 시설 등을 만드는 것에 관한 학문.




데이터 엔지니어링의 정의

- 데이터 엔지니어링은 데이터를 수집하고 활용할 수 있도록 시스템을 구축하는 것
- 대규모 데이터를 효율적으로 수집, 저장, 처리 및 전송하기 위한 기술과 인프라를 개발하는 작업




데이터 엔지니어링의 정의




Data Pipeline

- 데이터의 원천부터 시작하여 필요한 데이터를 추출하고, 그 데이터를 정제, 변환, 분석, 저장, 전달하는 일련의 과정
- 데이터를 시작점(A)에서 목적지(B)로 안전하고 신뢰성 있게 이동·전달하는 과정




Data Pipeline

- 데이터의 원천부터 시작하여 필요한 데이터를 추출하고, 그 데이터를 정제, 변환, 분석, 저장, 전달하는 일련의 과정
- 데이터를 시작점(A)에서 목적지(B)로 안전하고 신뢰성 있게 이동·전달하는 과정




Data Pipeline

- 데이터의 원천부터 시작하여 필요한 데이터를 추출하고, 그 데이터를 정제, 변환, 분석, 저장, 전달하는 일련의 과정
- 데이터를 시작점(A)에서 목적지(B)로 안전하고 신뢰성 있게 이동·전달하는 과정



ETL (Extract, Transform, Load)

- 다양한 원천에서 데이터를 추출(Extract)하여 원하는 형태로 변환(Transform)한 후 목적지에 적재(Load)하는 과정



ETL과 ELT

• ETL



- 데이터를 수집(E)한 후 변환 작업(T)을 먼저 수행한 다음 저장(L)하는 데이터 처리 과정
- 변환 과정을 통해 고품질의 데이터를 저장하여 바로 분석 가능.
- 데이터 변환 과정에서 시간이 오래 걸릴 수 있으며 변환을 위한 인프라와 리소스가 많이 필요함.
- 데이터 마트 구축, 일일 보고서 생성, 웹 로그 데이터 분석 등에 유용.

• ELT

- 데이터를 수집(E)한 후 변환 없이 먼저 저장소에 저장(L)한 후 변환 작업(T)을 수행하는 데이터 처리 과정
- 데이터를 저장한 후 다양한 변환 작업을 적용할 수 있어 유연함.
- 초기 데이터 적재 속도가 매우 빠르지만 적재된 데이터 품질이 낮고 활용성이 떨어질 수 있음.
- 저장소 리소스 낭비와 비용 증가의 가능성 있음.
- 빅 데이터 분석, 실시간 데이터 스트리밍 처리, 클라우드 데이터 레이크 관리, IoT 데이터 처리에 적합.



Batch & Streaming

- Batch : 많은 양의 데이터를 정해진 시간(매시, 매일, 매월, 매년 등)에 일괄적으로 처리하는 것
- Streaming : 실시간으로 들어오는 데이터를 그때그때 즉각적으로 처리하는 것 (초 단위)



데이터 엔지니어, 데이터 분석가, 데이터 과학자

- 데이터 엔지니어 : 대규모 데이터를 처리할 수 있는 데이터 인프라와 파이프라인 설계, 구축, 유지 및 관리 역할
- 데이터 분석가 : 데이터를 분석하여 유의미한 인사이트를 도출하고, 이를 바탕으로 비즈니스 의사결정을 지원하는 역할
- 데이터 과학자 : 데이터를 분석하고 예측 모델을 개발하여 복잡한 비즈니스 문제를 해결



데이터 엔지니어, 데이터 분석가, 데이터 과학자

	 데이터 엔지니어	 데이터 분석가	 데이터 과학자
핵심 역할	데이터 처리 인프라 및 파이프라인 설계, 구축, 유지	데이터를 분석하여 인사이트 도출 및 비즈니스 의사결정 지원	데이터 기반 문제 해결 및 예측 모델 개발
주요 업무	- ETL/ELT 파이프라인 개발 - 데이터 웨어하우스 설계 및 관리 - 데이터 정합성 및 품질 관리	- 리포트 작성 및 시각화 대시보드 제작 - 탐색적 데이터 & 비즈니스 성과 분석 - 데이터 파이프라인 개발	- 데이터 기반 통계적 분석 - 머신러닝/딥러닝 모델링 - 모델 성능 평가 및 배포
주요 도구	SQL, Python, Airflow, Spark, Kafka, Cloud, Kubernetes 등	SQL, Python, Cloud, Excel, Tableau, Power BI, Looker, Docker 등	- Python, SQL, Cloud, TensorFlow, PyTorch, ML/DL 관리 도구 등
데이터의 형태	원천 데이터, 로그, API 등 데이터 형태가 다양	정제된 정형 데이터 (테이블)	정제된 정형 데이터 (테이블), 자연어 등 비정형 데이터
산출물	데이터 레이크/웨어하우스, 파이프라인, API, 자동화 시스템	리포트, 대시보드, 지표 정의 문서, 인사이트 요약	모델, 알고리즘, 예측 결과, 실험 리포트
협업 대상	데이터 분석가, 데이터 과학자, 개발자	기획자, 마케팅팀, PM, 데이터 엔지니어	데이터 엔지니어, 분석가, 제품/AI 팀

데이터 엔지니어의 주요 업무

- 데이터가 효율적으로 흘러가고 처리될 수 있는 인프라 설계, 구축, 운영 및 유지보수
- End User(최종 사용자)가 원하는 데이터 제공을 위한 데이터 파이프라인 작업 개발
- 유입 or 유입된 데이터에 대한 관리 및 모니터링
- 여러가지 기술들 중 가장 적합한 Tool을 선택하여 파이프라인 아키텍처 구성




Garbage In Garbage Out

☞ 부정확한 입력 데이터가 주어지면 결과 또한 부정확하거나 쓸모없는 데이터가 나온다. 즉, 쓸모없는 데이터로는 의미있는 인사이트를 이끌어 낼 수 없다.

데이터 엔지니어의 주요 업무

- 데이터가 효율적으로 흘러가고 처리될 수 있도록 관련 인프라와 데이터 파이프라인 설계, 구축, 운영 및 유지보수
- Endpoint 유저가 원하는 데이터 제공을 위한 ETL 작업 개발
- 유입 or 유입된 데이터에 대한 관리 및 모니터링
- 여러가지 기술들 중 가장 적합한 Tool을 선택하여 파이프라인 아키텍처 구성



Garbage In ~~Garbage Out~~ Data Out

☞ 아무리 다루기 어려운(더러운) 형상의 데이터가 들어오더라도 이후 사용자가 가치 있게 활용할 수 있도록 데이터를 가공·정제한다.

데이터 엔지니어링 도구

SQL DATABASE

Relational OLTP DBMS

PostgreSQL
MySQL
MariaDB
supabase
SQLite

Distributed SQL DBMS

citusdata
CockroachDB
yugabyteDB
TiDB
OCEANBASE
ShardingSphere
NEON
CrateDB

NoSQL DATABASE

Cache Store

redis
Memcached
Dragonfly
Valkey

Document Store

mongoDB
CouchDB
RAVENDB
Couchbase
FerretDB

Graph Database

neo4j
JanusGraph
HugeGraph
NebulaGraph
Dgraph
AGE
FalkorDB

Distributed Key-value

FoundationDB
etcd
TiKV
immudb
Kvrocks

Wide-Column Key-value

CASSANDRA
HBASE
SCYLLA
ACCUMULO
Embedded Key-value
RocksDB
BadgerDB
MyRocks

OLAP DATABASE

Search Engine

Solr
elastic
meilisearch
OpenSearch
QUICKWIT
ParadeDB

Time-Series DB

influxdb
IOTDB
atlas
TIMESCALE
QuestDB
TDengine
HoraeDB
GreptimeDB

Columnar OLAP DB

monetdb
Databend
ByConity
HYDRA
Embeddable OLAP
DuckDB
GlareDB
DATAFUSION
chDB
SlateDB

Real-Time OLAP DB

ClickHouse
pinot
druid
Apache Kylin
DORIS
StarRocks

Streaming Database

RisingWave
Materialize
EVENT STORE
KsqlDB
proton
fluss

DATA LAKE PLATFORM

Distributed File System

hadoop HDFS
GLUSTER
JuiceFS
l-u-s-t-r-e

Open Table Format

hudi
ICEBERG
DELTA LAKE
Apache Paimon
OpenHouse

Serialisation Framework

Parquet
AVRO
ORC
Lance
vortex
Universal Table Format
Apache XTable
AMORO

Distributed Object Store

OZONE
ceph
MINIO

DATA INTEGRATION

Integration Platform

AIRBYTE
nifi
Camel
BOBLIN
InLong
Meltano
SeaTunnel
dltHub
multiwoven

CDC Frameworks

debezium
kafka connect
Flink CDC
brooklin
Redpanda Connect
rudderstack
Artie
PeerDB

Log & Event Collection

CloudQuery
SNOWFLOW
Event Mesh
steampipe
JITSU
Data Migration
DBMate
ingestr
Sling

Event Hub

Apache Kafka
NSQ
PULSAR
Apache RocketMQ
Redpanda
AutoMQ

DATA PROCESSING & COMPUTATION

Unified Processing

Apache Beam
Spark
Dinky
feldera

Stream Processing

Flink
samza
APACHE STORM
akka
bytwax
FastStream
Bento
Fluvio
StreamPark
arroyo

Python Processing

vaex
dask
Polars
PySpark
RAY
ARROW
SQLFrame
Ibis
daft
MODIN
RAPIDS cuDF

Batch Processing

hadoop MapReduce
TEZ

WORKFLOW & DATAOPS

Workflow Orchestration

Airflow
PREFECT
argo
Cadence
dagster
DolphinScheduler
Flyte
kestra
MAGE
Temporal
Windmill
maestro

Data Quality

great_expectations
SODA
pandera
Data Versioning
lakeFS
Project Nessie
DVC
Data Modeling
dbt Core
SQLMesh

DATA INFRASTRUCTURE & MONITORING

Resource Scheduling

hadoop YARN
MESOS
kubernetes
docker
YUNIKORN

Metrics Store

influxdb
Mimir
OPENTSDG
M3

Observability Framework

Prometheus
ELK
graphite
OpenTelemetry
VICTORIA METRICS
ZABBIX

Log & Metrics Pipeline

fluentd
fluentbit
logstash
telegraf
VECTOR BY DATADOG

Cluster Administration

Apache Ambari
HELIK

Security

APACHE KNOX
Apache Ranger
Kerberos

Monitoring Dashboard

Grafana
kibana
console

ML/AI PLATFORM

Vector Storage

milvus
drant
chroma
marqo
LanceDB
Weaviate
deeplake
Vespa
Vald
pgvector

MLOps Platform

mlflow
METAFLOW
SkyPilot
Jina
BENTOML
Determined AI
RAY
Kubeflow
Pachyderm
kedro

LLMops Platform

Haystack
Dify
superduper
cognee
vLLM

METADATA MANAGEMENT

Metadata Platform

Amundsen
Apache Atlas
Data Hub
MARQUEZ
ckan
Open Metadata
Platform

Catalog Service

Metastore
schema-registry
Unity Catalog
POLARIS CATALOG
lakekeeper
APACHE GRAVITINO
Open Standards
OpenLineage
Open Metadata
EGERIA

ANALYTICS & VISUALISATION

BI & Dashboard

Superset
Metabase
re-dash
Lightdash

BI AS CODE

Streamlit
plotly | Dash
Quary
MERCURY
Vizro
evidence

MPP Query Engine

HIVE
Apache Impala
presto
trino
APACHE DRILL
Semantic Layer
ALLUXIO
cube
Linkis
Gluten
APACHE OpenDAL


Query & Collaboration

hUE
Apache Zeppelin
Querybook
jupyter
marimo
Datasette


데이터 엔지니어링 도구

- https://whimsical.com/de_skills_CYXEYCaa3U4zNL5JTYKv59


1. 대용량 데이터 분석 및 시각화




2. 불용/유용 데이터 아카이빙 작업



3. 웹 API 수집을 통한 ETL 프로세스



4. AI 모델 개발용 실시간 데이터 적재



02 Apache Airflow 기초

데이터 엔지니어링 도구

SQL DATABASE

Relational OLTP DBMS

PostgreSQL
MySQL
MariaDB
supabase
SQLite

Distributed SQL DBMS

citusdata
CockroachDB
yugabyteDB
TiDB
OCEANBASE
ShardingSphere
NEON
CrateDB

NoSQL DATABASE

Cache Store

redis
Dragonfly
Valkey

Document Store

mongoDB
CouchDB
RAVENDB
Couchbase
FerretDB

Graph Database

neo4j
JanusGraph
HugeGraph
NebulaGraph
Dgraph
AGE
FalkorDB

Distributed Key-value

FoundationDB
etcd
TiKV
immudb
Kvrocks

Wide-Column Key-value

CASSANDRA
HBASE
SCYLLA
accumulo
Embedded Key-value
RocksDB
BadgerDB
MyRocks

OLAP DATABASE

Search Engine

Solr
elastic
meilisearch
OpenSearch
QUICKWIT
ParadeDB

Time-Series DB

influxdb
IOTDB
atlas
Grafana
TDengine
HoraeDB
GreptimeDB

Columnar OLAP DB

monetdb
Databend
ByConity
HYDRA
Embeddable OLAP
DuckDB
Glarer
StarRocks

Real-Time OLAP DB

ClickHouse
pinot
druid
DORIS

Streaming Database

RisingWave
Materialize
EVENT STORE
KsqlDB
proton
fluss

DATA LAKE PLATFORM

Distributed File System

hadoop HDFS
GLUSTER
JuiceFS
l-u-s-t-r-e

Distributed Object Store

OZONE
ceph
MINIO

Open Table Format

hudi
ICEBERG
DELTA LAKE
Apache Paimon
OpenHouse

Serialisation Framework

Parquet
ORC
Lance
vortex

Universal Table Format

Apache XTable
AMORO

DATA INTEGRATION

Integration Platform

AIRBYTE
nifi
Camel
BOBLIN
InLong
Meltano
SeaTunnel
dltHub
multiwoven

CDC Frameworks

debezium
kafka connect
Flink CDC
brooklin
Redpanda Connect
rudderstack
Artie
PeerDB

Log & Event Collection

CloudQuery
SNOWFLOW
Event Mesh
steampipe
JITSU
Data Migration
DBMate
ingestr
Sling

Event Hub

Apache Kafka
NSQ
PULSAR
Apache RocketMQ
Redpanda
AutoMQ

DATA PROCESSING & COMPUTATION

Unified Processing

Apache Beam
Spark
Dinky
feldera

Batch Processing

hadoop MapReduce
TEZ

Stream Processing

Flink
samza
APACHE STORM
akka
bytwax
FastStream
Bento
Fluvio
StreamPark
arroyo

Python Processing

vaex
dask
Polars
PySpark
RAY
ARROW
SQLFrame
Ibis
daft
MODIN
RAPIDS cuDF

WORKFLOW & DATAOPS

Workflow Orchestration

Airflow
PREFECT
argo
Cadence
dagster
DolphinScheduler
Flyte
kestra
MAGE
Temporal
Windmill
maestro

Data Quality

great_expectations
SODA
pandera
Data Versioning
lakeFS
Project Nessie
DVC
Data Modeling
dbt Core
SQLMesh

DATA INFRASTRUCTURE & MONITORING

Resource Scheduling

hadoop YARN
MESOS
kubernetes
docker
YUNIKORN

Cluster Administration

Apache Ambari
HELIX

Metrics Store

influxdb
Mimir
OPENTSDG
M3

Security

APACHE KNOX
Apache Ranger

Observability Framework

Prometheus
ELK
graphite
OpenTelemetry
VICTORIA METRICS
ZABBIX

Monitoring Dashboard

Grafana
kibana
console

Log & Metrics Pipeline

fluentd
fluentbit
logstash
telegraf
VECTOR BY DATADOG

ML/AI PLATFORM

Vector Storage

milvus
drant
chroma
marqo
LanceDB
Weaviate
deeplake
Vespa
Vald
pgvector

MLOps Platform

mlflow
METAFLOW
SkyPilot
Jina
BENTOML
Determined AI
RAY
Kubeflow
Pachyderm
kedro

LLMOps Platform

Haystack
Dify
superduper
cognee
vLLM

METADATA MANAGEMENT

Metadata Platform

Amundsen
Apache Atlas
Data Hub
MARQUEZ
ckan
Open Metadata
Platform

Catalog Service

Metastore
schema-registry
Unity Catalog
POLARIS CATALOG
lakekeeper
APACHE GRAVITINO
Open Standards
OpenLineage
Open Metadata
EGERIA

ANALYTICS & VISUALISATION

BI & Dashboard

Superset
Metabase
re-dash
Lightdash

Query & Collaboration

hUE
Apache Zeppelin
Querybook
jupyter
marimo
Datasette

BI AS CODE


Streamlit
plotly | Dash
Quary
MERCURY
Vizro
evidence

MPP Query Engine

HIVE
Apache Impala
presto
trino
APACHE DRILL
Semantic Layer
ALLUXIO
cube
Linkis
Gluten
APACHE OpenDAL

데이터 처리 작업


- 하나의 작업은 Input과 Output을 발생시킨다.



```
def extract_mysql():  
    print("MySQL에서 데이터를 추출합니다.")  
    return "mysql_data"  
  
def extract_pg():  
    print("PostgreSQL에서 데이터를 추출합니다.")  
    return "postgresql_data"
```


데이터 처리 작업

- 하나의 작업은 Input과 Output을 발생시킨다.
- Output을 Input으로 활용하여 또 다른 작업을 연속적으로 실행할 수 있다.




데이터 처리 작업

- 하나의 작업은 Input과 Output을 발생시킨다.
- Output을 Input으로 활용하여 또 다른 작업을 연속적으로 실행할 수 있다.




데이터 처리 작업

- 하나의 작업은 Input과 Output을 발생시킨다.
- Output을 Input으로 활용하여 또 다른 작업을 연속적으로 실행할 수 있다.
- 이러한 작업이 연속적으로 일어나게 되면 하나의 작업 파이프라인을 형성한다.




데이터 처리 작업

- 하나의 작업은 Input과 Output을 발생시킨다.
- Output을 Input으로 활용하여 또 다른 작업을 연속적으로 실행할 수 있다.
- 이러한 작업이 연속적으로 일어나게 되면 하나의 작업 파이프라인을 형성한다.



데이터 처리 작업


- 하나의 작업은 Input과 Output을 발생시킨다.
- Output을 Input으로 활용하여 또 다른 작업을 연속적으로 실행할 수 있다.
- 이러한 작업이 연속적으로 일어나게 되면 하나의 작업 파이프라인을 형성한다.
- 파이프라인 작업이 특정 주기로 실행되면(배치 작업) 작업에 대한 지속적인 결과물을 얻을 수 있다.



데이터 처리 작업

- 하나의 작업은 Input과 Output을 발생시킨다.
- Output을 Input으로 활용하여 또 다른 작업을 연속적으로 실행할 수 있다.
- 이러한 작업이 연속적으로 일어나게 되면 하나의 작업 파이프라인을 형성한다.
- 파이프라인 작업이 특정 주기로 실행되면(배치 작업) 작업에 대한 지속적인 결과물을 얻을 수 있다.


그렇다면 이 배치 작업을 누가 실행할까? 🤔



데이터 처리 작업


- 하나의 작업은 Input과 Output을 발생시킨다.
- Output을 Input으로 활용하여 또 다른 작업을 연속적으로 실행할 수 있다.
- 이러한 작업이 연속적으로 일어나게 되면 하나의 작업 파이프라인을 형성한다.
- 파이프라인 작업이 특정 주기로 실행되면(배치 작업) 작업에 대한 지속적인 결과물을 얻을 수 있다.

그렇다면 이 배치 작업을 누가 실행할까? 🤔



Orchestration 도구들의 등장

- 오케스트레이션 도구 → 여러 작업의 실행 순서, 의존 관계, 스케줄을 정의하고 자동으로 실행·관리해 주는 도구



Orchestration 도구 활용의 필요성

1. 데이터 복잡성과 볼륨 증가

- 빅데이터 시대의 도래로 정형, 비정형 데이터들의 복잡성 및 볼륨 증가

2. 다양한 파이프라인 환경 관리

- 분산 처리 도구, 클라우드 등 다양한 IT 기술 등장으로 데이터 관리 파이프라인이 복잡·다양화

3. 복잡한 워크플로우 효율적 제어

- 여러개의 작업이 연결되고, 동시에 수행되는 복잡한 파이프라인 작업에 대한 효율적인 관리 필요

4. 자동화·스케줄링·모니터링 통합

- 다수의 작업을 각기 다른 배치 간격으로 스케줄링하고 이를 통합적으로 모니터링 할 수 있도록 함

5. 안정적인 에러 처리와 재실행

- 작업 간에 에러 발생시, 에러 추적과 재수행을 용이하게 할 수 있도록 함

Apache Airflow의 등장

- 2014년 10월, Airbnb에서 사내 워크플로우에 대한 원활한 관리를 위해 개발
- 2015년 6월, Github에 오픈소스로 공개
- 2016년 3월, 아파치 재단 프로젝트로 편입
- 2016년 5월, Airflow 1.7.1 버전 릴리즈
- 2019년 1월, 아파치 재단 최상위 프로젝트로 승격
- 2020년 12월, Airflow 2.0.0 버전 릴리즈
- 2025년 2월, Airflow 2.10.5 버전 릴리즈
- 2025년 4월, Airflow 3.0.0 버전 릴리즈 (👉 [Airflow_Release_Notes](#))
- 2025년 8월, Airflow 3.0.5 버전 릴리즈

Apache Airflow의 특징

- Python 기반 작업

- Python으로 모든 작업 코드를 작성할 수 있어 데이터 관련 작업시 통합이 원활.

- 웹 기반 UI 제공

- Airflow UI를 통해 실행 현황 및 작업 상태에 대한 실시간 정보를 직관적으로 파악 가능

- 다양한 실행 환경

- Local, Sequential, Kubernetes, Celery 등 인프라 상황에 맞게 다양한 실행 환경에서 구동 가능


- 데이터 소스 및 서비스들과의 통합 (👉 [providers.list](#))

- 80개 이상의 연결 가능한 서비스와 1000개 이상의 오퍼레이터를 제공하여 거의 모든 데이터 관련 작업이 가능

- 강력한 스케줄링 기능

- Cron 표현식, 백필(Backfill), 캐치업(Catchup) 등 다양한 스케줄링 옵션을 제공하여 유연한 작업 실행을 지원

Apache Airflow의 점유율




03 Airflow 관련 용어 정리

DAG (Directed Acyclic Graph)

- '유향 비순환 그래프' 라는 뜻으로, 자신으로 되돌아오는 경로가 없는 그래프.
- 파이프라인 작업은 하나의 작업이 다른 작업에 의존하거나 특정 순서로 실행되어야 하기 때문에 방향성을 가진다.
- 작업의 실행 순서 보장과 무한 루프 방지 등을 위해 완료된 작업을 다시 호출할 수 없도록 강제한다.
- Airflow에서 하나의 온전한 파이프라인 작업 스크립트를 Dag라고 칭한다.

DAG → O



DAG → X

